

데이터셋 기초

Feature, Label, 데이터 품질, 데이터 분할, 과적합

이 문서는 DNN을 배우기 전에 반드시 이해해야 하는 데이터셋 개념을 다룬다. 단순한 정의가 아니라, 모델이 데이터를 어떻게 보고 왜 데이터 품질이 성능을 결정하는지까지 예시 중심으로 설명한다.



학습 목표

- 데이터셋이 무엇인지 설명할 수 있다.
- Feature와 Label을 예시로 구분할 수 있다.
- Train, Validation, Test 데이터를 왜 나누는지 이해할 수 있다.
- 클래스 불균형과 데이터 품질 문제를 설명할 수 있다.
- 과적합이 무엇인지 학습 곡선과 비유로 이해할 수 있다.

1. 데이터셋이란 무엇인가?

데이터셋은 인공지능 모델이 학습하기 위해 사용하는 데이터들의 집합이다. 사람은 경험을 통해 규칙을 배우지만, AI 모델은 데이터셋 안에 들어 있는 입력과 정답의 관계를 반복해서 보면서 규칙을 학습한다.

예를 들어 숫자 손글씨를 분류하는 모델을 만든다면, 모델에게는 손글씨 이미지와 그 이미지가 어떤 숫자인지를 알려주는 정답이 함께 필요하다. 이때 이미지 한 장과 정답 숫자 하나가 합쳐져 하나의 학습 샘플이 된다.

핵심 정의

데이터셋 = 여러 개의 샘플 모음. 각 샘플은 보통 입력값 x 와 정답 y 로 구성된다.

용어	의미	예시
Sample	데이터셋을 이루는 하나의 데이터 단위	손글씨 이미지 1장 + 정답 7
Feature	모델에게 입력되는 정보	이미지 픽셀값, 키, 몸무게, 공부 시간
Label	모델이 맞춰야 하는 정답	숫자 7, 고양이, 집 가격

데이터셋을 AI의 교과서라고 생각하면 쉽다. 교과서 내용이 부족하거나 틀리면 학생이 잘못 배우듯이, 데이터셋이 부족하거나 라벨이 틀리면 모델도 잘못 학습한다.

2. Feature: 모델이 보는 입력 정보

Feature는 모델에게 입력되는 정보이다. 이미지 문제에서는 픽셀값이 feature이고, 표 데이터에서는 키, 몸무게, 나이, 공부 시간 같은 열이 feature가 된다. 모델은 feature를 보고 label을 맞는 규칙을 찾는다.

예시: 학생 합격 여부 예측

공부 시간	출석률	과제 점수	정답 레이블
8시간	95%	90점	합격
2시간	60%	40점	불합격
5시간	80%	75점	합격 가능성 높음

위 표에서 공부 시간, 출석률, 과제 점수는 모델이 참고하는 입력 정보이다. 반면 합격 여부는 모델이 맞춰야 하는 정답이다. 즉, feature는 문제의 단서이고 label은 답이다.

이미지 데이터의 Feature

이미지도 결국 숫자 배열이다




그림. 이미지는 사람이 보기에는 그림이지만, 모델에게는 픽셀 숫자 배열로 입력된다.

이미지 분류에서 모델은 “고양이처럼 보인다”라는 감각으로 판단하지 않는다. 실제로는 각 픽셀의 밝기값이나 색상값을 숫자로 입력받고, 그 숫자 패턴을 이용해 정답을 예측한다.

3. Label: 모델이 맞혀야 하는 정답

Label은 모델이 예측해야 하는 정답이다. 분류 문제에서는 label이 클래스 이름이고, 회귀 문제에서는 실제 숫자 값이다.

문제 유형	입력 Feature	Label 예시
이미지 분류	사진 이미지	고양이, 강아지, 자동차
숫자 분류	손글씨 이미지	0, 1, 2, ..., 9
집값 예측	면적, 위치, 방 개수	3억, 5억 같은 가격
성적 예측	공부 시간, 출석률, 과제 점수	최종 점수

라벨이 중요한 이유

라벨이 잘못되어 있으면 모델은 잘못된 규칙을 배운다. 강아지 사진에 고양이라는 라벨이 붙어 있으면, 모델은 강아지의 특징을 고양이 특징으로 학습할 수 있다. 이런 오류가 많아지면 모델은 점점 혼란스러워진다.

예시

- 정상 데이터: 강아지 사진 → Label = dog
- 잘못된 데이터: 강아지 사진 → Label = cat
- 결과: 모델은 강아지와 고양이의 차이를 흐리게 학습한다.

따라서 좋은 모델을 만들려면 복잡한 알고리즘만 중요한 것이 아니라, 정확한 라벨을 가진 데이터셋을 준비하는 일이 먼저 필요하다.

4. 데이터셋의 품질: 양보다 중요한 것은 “잘 대표하는가”

데이터가 많으면 보통 도움이 되지만, 단순히 개수만 많다고 좋은 데이터셋은 아니다. 실제 상황을 잘 대표하고, 라벨이 정확하며, 다양한 경우를 포함해야 한다.

데이터 분포와 노이즈 예시




그림. 데이터가 잘 분리되면 모델이 규칙을 배우기 쉽지만, 노이즈와 겹침이 많으면 어려워진다.


좋은 데이터셋의 조건

조건	의미	부족할 때 문제
충분한 양	모델이 다양한 예시를 볼 수 있음	몇 개 샘플만 외우기 쉬움
정확한 라벨	정답이 신뢰 가능함	잘못된 방향으로 학습
다양성	실제 상황의 변화를 포함함	처음 보는 상황에서 약함
균형	클래스별 데이터 수가 지나치게 치우치지 않음	많은 클래스만 잘 맞힘
일관성	수집 방식과 기준이 일정함	불필요한 차이를 규칙으로 오해

5. 클래스 불균형이란?

클래스 불균형은 어떤 클래스의 데이터는 매우 많고, 다른 클래스의 데이터는 매우 적은 상태를 말한다. 분류 모델은 많이 본 클래스에 유리하게 학습되기 때문에 불균형이 심하면 성능 해석이 왜곡될 수 있다.

클래스 불균형 예시



많은 클래스만 잘 맞는 편향이 생길 수 있음

그림. 고양이 데이터가 압도적으로 많으면 모델은 고양이 쪽으로 편향될 수 있다.

예를 들어 고양이 사진 1000장, 강아지 사진 80장, 토끼 사진 45장으로 모델을 학습한다고 하자. 모델은 고양이를 많이 보았기 때문에 고양이는 잘 맞하지만, 강아지와 토끼는 잘 구분하지 못할 수 있다.

왜 정확도만 보면 위험한가?

전체 데이터의 95%가 고양이라면, 모델이 모든 이미지를 고양이라고 예측해도 정확도가 95%처럼 보일 수 있다. 하지만 이 모델은 강아지와 토끼를 전혀 구분하지 못하므로 좋은 모델이라고 볼 수 없다.

해결 방향

- 적은 클래스의 데이터를 추가로 수집한다.
- 많은 클래스의 일부를 줄여 균형을 맞춘다.
- 손실 함수에서 적은 클래스에 더 큰 가중치를 준다.
- 정확도만 보지 말고 precision, recall, F1-score 같은 지표도 함께 본다.

6. 데이터 분할: Train, Validation, Test

모델을 만들 때 모든 데이터를 한 번에 학습에만 사용하면 안 된다. 모델이 정말 새로운 데이터에서도 잘 작동하는지 확인하기 위해 데이터셋을 역할별로 나누어야 한다.

데이터셋 분할 구조




그림. 일반적인 데이터 분할 예시. 비율은 문제와 데이터 크기에 따라 달라질 수 있다.

데이터 종류	역할	비유
Train	모델이 직접 학습하는 데이터	교과서
Validation	학습 중 성능을 점검하고 설정을 조정하는 데이터	모의고사
Test	최종 성능을 평가하는 데이터	최종 시험

중요한 점은 test 데이터는 마지막 평가 전까지 최대한 건드리지 않는 것이다. test 데이터를 반복해서 보며 모델을 고치면, test 데이터도 사실상 학습에 사용한 것과 비슷해진다. 그러면 최종 성능이 실제보다 좋게 보일 수 있다.

7. 과적합이란?


과적합은 모델이 학습 데이터에는 지나치게 잘 맞지만, 새로운 데이터에는 잘 맞지 않는 현상이다. 쉽게 말해 원리를 이해한 것이 아니라 기출문제 답을 외운 상태와 비슷하다.

시험 비유

어떤 학생이 기출문제 “ $2 + 3 = 5$ ”, “ $4 + 1 = 5$ ”의 답만 외웠다고 하자. 이 학생은 같은 문제가 나오면 맞힐 수 있지만, “ $7 + 6$ ”처럼 새로운 문제가 나오면 풀지 못한다. 덧셈 원리를 배운 것이 아니라 특정 문제만 외웠기 때문이다.

AI 모델도 마찬가지다. 학습 데이터의 작은 특징, 배경, 노이즈까지 외우면 train 데이터에서는 성능이 높지만 test 데이터에서는 성능이 낮아진다.

과적합이 나타나는 학습 곡선 예시



Epoch가 증가해도 새로운 데이터 성능은 나빠질 수 있음

그림. Train Loss는 계속 감소하지만 Validation Loss가 다시 증가하면 과적합 신호일 수 있다.

상태	Train 성능	Validation/Test 성능	해석
정상 학습	좋음	좋음	일반적인 규칙을 잘 배움
과소적합	낮음	낮음	모델이 너무 단순하거나 학습 부족
과적합	매우 좋음	낮음	학습 데이터를 외워버림

8. 과적합이 발생하는 대표 원인

과적합은 보통 데이터와 모델의 균형이 맞지 않을 때 발생한다. 모델이 표현할 수 있는 규칙은 너무 복잡한데, 데이터가 충분히 다양하지 않으면 모델은 일반 규칙 대신 학습 데이터를 외우기 쉽다.

원인	설명	예시
데이터가 너무 적음	다양한 상황을 보지 못함	고양이 사진 5장만 학습

원인	설명	예시
모델이 너무 복잡함	데이터보다 모델의 표현력이 과함	작은 데이터에 매우 깊은 모델 사용
학습을 너무 오래 함	처음에는 일반 규칙을 배우다가 나중에는 노이즈까지 외움	Validation loss가 증가하는데 계속 학습
라벨 오류/노이즈	잘못된 정보를 규칙으로 학습	강아지 사진에 cat 라벨
데이터 다양성 부족	특정 조건에만 익숙해짐	밝은 배경의 고양이만 학습

과적합은 모델이 똑똑해서 생긴다기보다, 주어진 데이터 안에서 너무 세밀한 규칙까지 맞추려고 해서 생기는 문제다.

9. 과적합을 줄이는 방법

과적합을 줄이는 핵심은 모델이 학습 데이터만 외우지 않고 새로운 데이터에도 통하는 일반적인 규칙을 배우도록 만드는 것이다.

대표 방법

방법	핵심 아이디어	예시
데이터 추가	더 다양한 예시를 보여줌	다양한 각도/배경의 이미지 수집
데이터 증강	기존 데이터를 변형해 다양성 증가	회전, 밝기 조절, 좌우 반전
Dropout	학습 중 일부 뉴런을 임시로 끄	특정 경로에만 의존하지 않게 함
Weight Decay	가중치가 지나치게 커지지 않게 제한	복잡한 규칙 억제
Early Stopping	검증 성능이 나빠지기 전에 멈춤	Validation loss 증가 시 중단

데이터 증강 예시

고양이 이미지를 살짝 회전하거나 밝기를 바꾸어도 여전히 고양이이다. 이런 변형을 학습에 포함하면 모델은 특정 사진 한 장을 외우기보다, 고양이를 나타내는 일반적인 특징을 배우게 된다.

정리하면, 과적합 해결은 “모델을 약하게 만들기”가 아니라 “새로운 데이터에도 통하는 규칙을 배우게 만들기”에 가깝다.

10. 데이터셋을 볼 때 확인해야 할 체크리스트

딥러닝 모델을 학습하기 전에는 데이터셋을 먼저 점검해야 한다. 모델 구조를 바꾸기 전에 데이터 자체가 학습 가능한 상태인지 확인하는 것이 중요하다.

점검 항목	확인 질문
데이터 개수	각 클래스별 데이터가 충분한가?
라벨 정확도	잘못 붙은 정답은 없는가?
클래스 균형	특정 클래스만 지나치게 많은가?
데이터 다양성	배경, 각도, 조명, 형태가 다양한가?
중복 데이터	같은 데이터가 너무 많이 반복되지 않는가?
Train/Test 분리	평가 데이터가 학습에 섞이지 않았는가?
실제 사용 환경과 유사성	학습 데이터가 실제 서비스 상황을 잘 반영하는가?

이 체크리스트는 모델 성능이 낮을 때도 유용하다. 성능이 낮다고 바로 DNN 구조를 더 복잡하게 만들기보다, 데이터가 부족한지, 라벨이 틀렸는지, 불균형이 심한지 먼저 확인해야 한다.

11. 전체 요약

- 데이터셋은 AI 모델이 학습하는 자료이며, 여러 개의 샘플로 구성된다.
- Feature는 모델에게 주어지는 입력 정보이고, Label은 모델이 맞춰야 하는 정답이다.
- 라벨이 틀리면 모델도 틀린 방향으로 학습한다.
- 좋은 데이터셋은 양, 품질, 다양성, 균형을 함께 갖추어야 한다.
- Train, Validation, Test 데이터를 나누어야 모델의 일반화 성능을 확인할 수 있다.
- 과적합은 학습 데이터를 외워서 새로운 데이터에 약해지는 현상이다.
- 과적합은 데이터 추가, 데이터 증강, Dropout, Weight Decay, Early Stopping 등으로 줄일 수 있다.

한 줄 정리

AI 모델은 데이터셋을 통해 세상을 배우므로, 좋은 학습은 좋은 데이터셋에서 시작된다.

다음 챕터 예고

다음 챕터에서는 이번 문서에서 설명한 feature와 label을 실제로 입력받아 예측을 수행하는 DNN의 구조, 층, 가중치, 활성화 함수, 손실 함수, 학습 과정을 분리해서 다룬다.